

# Онлайн-курс “Быстрый старт в искусственный интеллект”

## Модуль 1. Машинное обучение

### Дополнительные материалы к уроку 1.3 “Метрики машинного обучения”

Напомним, что в видеолекции мы подробно поговорили о метриках в задаче классификации. В этом материале мы поговорим о метриках в задаче регрессии.

Две самые распространённые метрики в задаче регрессии, о которых мы уже говорили, это  $MSE$  (mean squared error) и  $MAE$  (mean absolute error). Они вычисляются по следующим формулам:

$$MSE(y_{true}, y_{pred}) = \frac{1}{\ell} \sum_{i=1}^{\ell} (y_{true}^i - y_{pred}^i)^2;$$
$$MAE(y_{true}, y_{pred}) = \frac{1}{\ell} \sum_{i=1}^{\ell} |y_{true}^i - y_{pred}^i|.$$

Также часто используют метрику  $RMSE$  (rooted mean squared error), равную корню квадратному из  $MSE$ , и  $MAPE$  (mean absolute percentage error), которая вычисляется по формуле

$$MAPE(y_{true}, y_{pred}) = \frac{1}{\ell} \sum_{i=1}^{\ell} \left| \frac{y_{true}^i - y_{pred}^i}{y_{true}^i} \right|.$$

Последняя метрика хороша тем, что измеряет среднее значение абсолютной ошибки в процентах от реального значения целевой переменной.

Последняя метрика, о которой мы поговорим, называется  $R^2$  (произносится “ $R$ -квадрат”), или коэффициент детерминации. Она вычисляется по формуле

$$R^2(y_{true}, y_{pred}) = 1 - \frac{\sum_{i=1}^{\ell} (y_{true}^i - y_{pred}^i)^2}{\sum_{i=1}^{\ell} (y_{true}^i - \overline{y_{true}})^2},$$

где  $\overline{y_{true}}$  — среднее истинное значение целевой переменной. Здесь в числителе стоит  $MSE$ , домноженное на  $\ell$ , а в знаменателе — выборочная дисперсия выборки  $y_{true}$ , также домноженная на  $\ell$ .

Заметим, что если положить  $y_{pred}$  тождественно равным среднему значению целевой переменной:  $\overline{y_{true}}$ , то  $R^2$  становится равным 0. Из этого следует, что константная модель машинного обучения, которая предсказывает среднее значение целевой переменной независимо от объектов, имеет  $R^2 = 0$ .

При этом заметим, что  $R^2$  может быть сколь угодно малым отрицательным числом. Такие модели неадекватны, поскольку результат их работы хуже константной модели.

Кроме того, очевидно,  $R^2$  не превосходит 1. Таким образом, значения метрики для “адекватных” моделей находятся в промежутке  $[0, 1]$ . Для приемлемых моделей предполагается, что коэффициент детерминации должен быть не менее 0.5. Модели с коэффициентом детерминации выше 0.8 считаются весьма хорошими. Значение коэффициента детерминации 1 означает функциональную зависимость между переменными.